



华南理工大学

South China University of Technology

《机器学习》课程实验报告

学 院 软件学院

专 业 软件工程

组 员 韩松岳

学 号 201536471115

邮 箱 han14122@163.com

指导教师 吴庆耀

提交日期 2017 年 12 月 15 日

1. 实验题目: 逻辑回归、线性分类与随机梯度下降

2. 实验时间: 2017 年 12 月 2 日

3. 报告人: 韩松岳

4. 实验目的:

1. 对比理解梯度下降和随机梯度下降的区别与联系。
2. 对比理解逻辑回归和线性分类的区别与联系。
3. 进一步理解 SVM 的原理并在较大数据上实践。

5. 数据集以及数据分析:

实验使用的是 LIBSVM Data 中的 a9a 数据, 包含 32561 / 16281(testing) 个样本, 每个样本有 123/123 (testing) 个属性。

6. 实验步骤:

逻辑回归与随机梯度下降

1. 读取实验训练集和验证集。
2. 逻辑回归模型参数初始化, 可以考虑全零初始化, 随机初始化或者正态分布初始化。
3. 选择 Loss 函数及对其求导, 过程详见课件 ppt。
4. 求得部分样本对 Loss 函数的梯度。
5. 使用不同的优化方法更新模型参数 (NAG, RMSProp, AdaDelta 和 Adam)。
6. 选择合适的阈值, 将验证集中计算结果大于阈值的标记为正类, 反之为负类。在验证集上测试并得到不同优化方法的 Loss 函数值, , 和。
7. 重复步骤 4-6 若干次, 画出, , 和随迭代次数的变化图。

线性分类与随机梯度下降

1. 读取实验训练集和验证集。
2. 支持向量机模型参数初始化, 可以考虑全零初始化, 随机初始化或者正态分布初始化。
3. 选择 Loss 函数及对其求导, 过程详见课件 ppt。
4. 求得部分样本对 Loss 函数的梯度。
5. 使用不同的优化方法更新模型参数 (NAG, RMSProp, AdaDelta 和 Adam)。
6. 选择合适的阈值, 将验证集中计算结果大于阈值的标记为正类, 反之为负类。在验证集上测试并得到不同优化方法的 Loss 函数值, , 和。
7. 重复步骤 4-6 若干次, 画出, , 和随迭代次数的变化图。

7. 代码内容:

```
def get_batch(X_train, y_train):
    #打乱矩阵 取batch
    random_sequence = np.arange(X_train.shape[0])
    np.random.shuffle(random_sequence)
    X_batch = np.zeros((batch_size, dimension))
    y_batch = np.zeros(batch_size)
    for i in range(batch_size):
        X_batch[i] = X_train[random_sequence[i], :]
        y_batch[i] = y_train[random_sequence[i]]
    return X_batch, y_batch
```

```
def gradient (X, y, w):
    g = np.zeros(X.shape[1]) #存放 hinge loss 的梯度
    for i in range(X.shape[0]): #对每一条记录迭代一次
        judge = y[i] * np.dot(X[i], w.reshape(dimension, 1)) #分段函数 判断
        if (judge < 1): #小于1 则更新g 否则 g = g + 0
            g = g - y[i] * X[i]
    G = w + C * g #计算梯度G
    return G
```

```
def loss (X, y, w):
    loss = 0
    for i in range(X.shape[0]):
        judge = y[i] * np.dot(X[i], w.reshape(dimension, 1)) #分段函数 判断y * X * W与1的大小
        if (judge >= 1):
            loss = loss + 0 #大于1 hinge loss = 0
        else:
            loss = loss + 1 - judge #小于1 加上 1 - y * X * W
    loss = np.dot(w, w.reshape(dimension, 1)) / 2 + C * loss / X.shape[0] #loss取平均
    return loss
```

```
def NAG(w, v, g, eta=0.05, gama=0.9):
    v = gama * v + eta * g
    w = w - v
    return w, v
```

```
def RMSProp(w, G, g, gama=0.9, eta=0.001, epsilon=1e-8):
    G = gama * G + (1 - gama) * np.dot(g, g.reshape(g.shape[0], 1))
    w = w - (eta / np.sqrt(G + epsilon)) * g
    return w, G
```

```
def AdaDelta(w, G, g, delta, gama=0.95, epsilon=1e-6):
    G = gama * G + (1-gama) * np.dot(g, g)
    delta_w = -(np.sqrt(delta + epsilon) / np.sqrt(G + epsilon)) * g
    w = w + delta_w
    delta = gama * delta + (1-gama) * np.dot(delta_w, delta_w.reshape(delta_w.shape[0], 1))
    return w, G, delta
```

```
def Adam(w, m, G, g, t, beta=0.9, gama=0.999, eta=0.002, epsilon=1e-8):
    m = beta * m + (1-beta) * g
    G = gama * G + (1-gama) * np.dot(g, g.reshape(g.shape[0], 1))
    a = eta * np.sqrt(1 - np.power(gama, t))
    w = w - (a / np.sqrt(G + epsilon)) * m
    t = t + 1
    return w, m, G, t
```

```
def NAG_run(X_train, y_train, X_test, y_test, w):
    gama = 0.9
    v = np.zeros(dimension)
    NAG_loss = np.zeros(iter) #初始化 存放NAG法的验证集loss的向量
    for i in range(iter): #迭代
        NAG_loss[i] = loss(X_test, y_test, w)
        g = gradient(X_train, y_train, w - gama * v)
        w, v = NAG(w, v, g)
    return NAG_loss
```

```
def RMSProp_run(X_train, y_train, X_test, y_test, w):
    G = 0
    RMSProp_loss = np.zeros(iter) #初始化 存放NAG法的验证集loss的向量
    for i in range(iter):
        RMSProp_loss[i] = loss(X_test, y_test, w)
        g = gradient(X_train, y_train, w)
        w, G = RMSProp(w, G, g)
    return RMSProp_loss
```

```
def AdaDelta_run(X_train, y_train, X_test, y_test, w):
    G = 0
    delta = 0
    AdaDelta_loss = np.zeros(iter)
    for i in range(iter):
        AdaDelta_loss[i] = loss(X_test, y_test, w)
        g = gradient(X_train, y_train, w)
        w, G, delta = AdaDelta(w, G, g, delta)
    return AdaDelta_loss
```

```
def Adam_run(X_train, y_train, X_test, y_test, w):
    m = np.zeros(dimension)
    G = 0
    t = 0
    Adam_loss = np.zeros(iter)
    for i in range(iter):
        Adam_loss[i] = loss(X_test, y_test, w)
        g = gradient(X_train, y_train, w)
        w, m, G, t = Adam(w, m, G, g, t)
    return Adam_loss
```

(针对逻辑回归和线性分类分别填写 8-11 内容)

7. 模型参数的初始化方法:

逻辑回归: 正态分布初始化

线性分类: 正态分布初始化

8. 选择的 loss 函数及其导数:

逻辑回归 loss 函数:

$$J(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \log(1 + e^{-y_i \cdot \mathbf{w}^\top \mathbf{x}_i}) + \frac{\lambda}{2} \|\mathbf{w}\|_2^2$$

逻辑回归 loss 函数梯度:

$$\frac{\partial J(w)}{\partial w} = \lambda \vec{w} - \frac{1}{n} \sum_{i=1}^n \frac{y_i}{1 + e^{y_i w^T x_i}} \cdot \vec{x}_i$$

线性分类 loss 函数:

$$\text{hinge loss} = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i (w^T x_i + b))$$

线性分类 loss 函数梯度:

$$\frac{\partial L}{\partial w} = w + C \times g$$

$$g = \begin{cases} 0 & , y_i \times (w^T \vec{x}_i + b) \geq 1 \\ -y_i \times \vec{x}_i & , y_i \times (w^T \vec{x}_i + b) < 1 \end{cases}$$

10.实验结果和曲线图: (各种梯度下降方式分别填写此项)

NAG:

超参数选择: eta=0.05, gama=0.9

RMSProp:

超参数选择: gama=0.9, eta=0.001, epsilon=1e-8

AdaDelta:

超参数选择: gama=0.95, epsilon=1e-6

Adam:

超参数选择： $\beta=0.9$, $\gamma=0.999$, $\eta=0.002$, $\epsilon=1e-8$

11.实验结果分析:

在逻辑回归中，NAG_loss 下降最快，其次是 AdaDelta, RMSProp, Adam
在 SVM 线性分类中，Adam 下降最快，其次是 RMSProp, NAG, AdaDelta

12.对比逻辑回归和线性分类的异同点:

逻辑回归，线性分类使用相同的优化方法，不同的 loss 函数

13.实验总结:

在这次实验中，我学习到了多种高级梯度下降优化方法，发现理解了不同优化方法的优缺点以及适用的环境。在今后的学习中要善于运用不同的优化算法，在必要时可以尝试自己改进。